

Raspoznavanje znakova znakovnog jezika primjenom dubokih neuronskih mreža

Lucija Čorak, Mateo Jakšić, Petar Kuruc, Martina Šola, Klara Zagajski

Sažetak

U ovom radu istražuju se metode klasifikacije znakova znakovnog jezika korištenjem dubokih neuronskih mreža. Razmatrani su vlastiti CNN model te tri unaprijed istrenirana modela: MobileNetV2, EfficientNetB0 i ResNet50. Usporedba se provodi na temelju metrika: točnost, preciznost, odziv, F1-mjera, broj parametara i vrijeme treniranja.

1. Uvod

Znakovni jezik predstavlja osnovno sredstvo komunikacije za gluhe i nagluhe osobe. Automatizirano prepoznavanje znakova znakovnog jezika omogućuje razvoj inkluzivnih tehnologija i alata za lakšu komunikaciju. U ovom radu uspoređuju se četiri duboka modela trenirana na istom skupu podataka, s ciljem analize učinkovitosti pojedinih arhitektura.

2. Korišteni skup podataka

Korišten je javno dostupan skup podataka znakova američkog znakovnog jezika (ASL), koji se sastoji od slika koje prikazuju ruke u različitim pozicijama koje odgovaraju slovima engleske abecede. Skup je podijeljen na trening, validacijski i testni dio.

Skup podataka dostupan je na platformi Kaggle: Sign Language MNIST [6].

Radi se o slikama dimenzije 28×28 piksela u sivim tonovima, a svaka slika prikazuje jednu gestu koja odgovara slovu engleske abecede (osim slova *J* i *Z*, koja uključuju pokret i nisu zastupljena u ovom skupu).

Podaci su raspodijeljeni na sljedeći način:

- Trening skup: X uzoraka

- Validacijski skup: Y uzoraka
- Testni skup: Z uzoraka

3. Obrada slike

Prije treniranja modela provedena je obrada ulaznih slika kako bi se poboljšala kvaliteta podataka i omogućila robusnost modela.

3.1. Promjena dimenzija i skaliranje

Sve slike su skalirane na istu dimenziju $X \times X$ piksela kako bi se zadovoljili ulazni zahtjevi mreža. Pikselske vrijednosti su normalizirane na raspon $[0, 1]$.

3.2. Augmentacija podataka

Kako bi se smanjilo pretreniranost i povećala generalizacija modela, korištena je augmentacija slika. Primijenjene su sljedeće transformacije:

- Horizontalna i vertikalna translacija
- Rotacija (do X°)
- Zrcaljenje (horizontalno)
- Zoomiranje (unutar raspona $[Y_1, Y_2]$)

3.3. Podjela skupa

Skup podataka podijeljen je na tri dijela:

- Trening skup: $X\%$ uzoraka
- Validacijski skup: $Y\%$ uzoraka
- Testni skup: $Z\%$ uzoraka

3.4. Standardizacija prema modelu

Za pretrenirane modele (MobileNetV2, EfficientNetB0, ResNet50) korištene su odgovarajuće metode predobrade iz biblioteke `tensorflow.keras.applications`, koje uključuju:

- Središnjenje pikselских vrijednosti
- Skaliranje prema statistici skupa na kojem je model treniran

4. Modeli

4.1. Model 1: CNN

4.2. Model 2: MobileNetV2

4.3. Model 3: EfficientNetB0

4.4. Model 4: ResNet

5. Usporedba modela

5.1. Korištene metrike

Za kvantitativnu usporedbu korištene su sljedeće metrike:

- **Točnost (Accuracy)** – ukupni broj točnih klasifikacija u odnosu na ukupan broj uzoraka.
- **Preciznost (Precision)** – omjer ispravno predviđenih pozitivnih uzoraka u odnosu na sve predviđene pozitivne uzorke.
- **Odziv (Recall)** – omjer ispravno predviđenih pozitivnih uzoraka u odnosu na sve stvarne pozitivne uzorke.
- **F1-mjera (F1 Score)** – harmonijska sredina preciznosti i odziva.

5.2. Tablična usporedba rezultata

Metrička mjera	CNN	ResNet	M3	M4
Točnost (%)	X1	X2	X3	X4
Preciznost (%)	Y1	Y2	Y3	Y4
Odziv (%)	Z1	Z2	Z3	Z4
F1-mjera (%)	W1	W2	W3	W4
Vrijeme treniranja	T1	T2	T3	T4
Broj parametara	P1	P2	P3	P4

Tablica 1.: Usporedba performansi modela prema različitim metrima

5.3. Diskusija

Nakon provođenja eksperimenta, može se primijetiti da pojedini modeli ostvaruju bolje rezultate ovisno o metrikama i resursima. Vrijeme treniranja i broj parametara značajno utječu na mogućnosti primjene u stvarnim okruženjima.

6. Zaključak

.

Literatura

- [1] TensorFlow documentation, <https://www.tensorflow.org/>
- [2] Keras API reference, <https://keras.io/api/>
- [3] Sandler, M., et al. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *CVPR*.
- [4] Tan, M., & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *ICML*.
- [5] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR*.
- [6] DataMunge. Sign Language MNIST, <https://www.kaggle.com/datasets/datamunge/sign-language-mnist>